## 5. Spark Streaming. Stateful streams

Загрузить в топик kafka свои данные, прочитать их в потоке, применить watermark и window. Повторить шаги выполненные на занятии.

Дополнительно, объединить статичный и динамичный потоки. Задание на повышенный бал: Написать скрипт на python для конвертации файла csv в json.

#### Задание 1. Запустить агрегацию по временному окну в разных режимах.

1\.1\. Подключаемся к серверу

ssh -i ~/.ssh/id rsa student898 2 <u>student898\_2@37.139.41.176</u>

смотрим лист топиков

/usr/hdp/current/kafka-broker/bin/kafka-topics.sh --zookeeper bigdataanalytics-worker-3:2181 -- list

```
student898_2@bigdataanalytics-worker-3:~ - Терминал
Файл Правка Вид Терминал Вкладки Справка
[student898_2@bigdataanalytics-worker-3 ~]$ /usr/hdp/current/kafka-broker/bin/kafka-topics.sh --zookeeper bigdataanalytics-worker-3:2181 --list
MTG
 consumer offsets
cherneev-test
cherneev test
incident event json
life expectancy
markevich
oganesyan les2
order items
orders_json
shadrin iris
shadrin iris sink
student559 12
student559_8_lesson2
test-lesson2
test_lesson2_1
test_lesson_2_sapr
tolstykov_les4
tolstykov_les4_sink
```

Прочитать топик shadrin\_iris

[student898\_2@bigdataanalytics-worker-3 ~]\$

/usr/hdp/current/kafka-broker/bin/kafka-console-consumer.sh --topic shadrin\_iris --from-beginning --bootstrap-server bigdataanalytics-worker-3:6667 --max-messages 15

```
Файл Правка Вид Терминал Вкладки Справка
[student898_2@bigdataanalytics-worker-3 ~]$ /usr/hdp/current/kafka-broker/bin/kafka-console-consumer.sh --topic shadrin_iris --from-beginning --bootst
 rap-server bigdataanalytics-worker-3:6667 --max-messages 15
     {"sepalLength": 5.1, "sepalWidth": 3.5, "petalLength": 1.4, "petalWidth": 0.2, "species": "setosa"}, {"sepalLength": 4.9, "sepalWidth": 3.0, "petalLength": 1.4, "petalWidth": 0.2, "species": "setosa"}, {"sepalLength": 4.7, "sepalWidth": 3.2, "petalLength": 1.3, "petalWidth": 0.2, "species": "setosa"}, {"sepalLength": 4.6, "sepalWidth": 3.1, "petalLength": 1.5, "petalWidth": 0.2, "species": "setosa"}, {"sepalLength": 5.0, "sepalWidth": 3.6, "petalLength": 1.4, "petalWidth": 0.2, "species": "setosa"}, {"sepalLength": 5.4, "sepalWidth": 3.9, "petalLength": 1.7, "petalWidth": 0.4, "species": "setosa"}, {"sepalLength": 4.6, "sepalWidth": 3.4, "petalLength": 1.4, "petalWidth": 0.3, "species": "setosa"}, {"sepalLength": 5.0, "sepalWidth": 2.9, "petalLength": 1.5, "petalWidth": 0.2, "species": "setosa"}, {"sepalLength": 4.9, "sepalWidth": 3.1, "petalLength": 1.5, "petalWidth": 0.1, "species": "setosa"}, {"sepalLength": 5.4, "sepalWidth": 3.7, "petalLength": 1.5, "petalWidth": 0.2, "species": "setosa"}, {"sepalLength": 5.4, "sepalWidth": 3.7, "petalLength": 1.5, "petalWidth": 0.2, "species": "setosa"}, {"sepalLength": 5.4, "sepalWidth": 3.7, "petalLength": 1.5, "petalWidth": 0.2, "species": "setosa"}, {"sepalLength": 5.4, "sepalWidth": 3.7, "petalLength": 1.5, "petalWidth": 0.2, "species": "setosa"}, {"sepalLength": 5.4, "sepalWidth": 3.7, "petalLength": 1.5, "petalWidth": 0.2, "species": "setosa"}, {"sepalLength": 5.4, "sepalWidth": 3.7, "petalLength": 1.5, "petalWidth": 0.2, "species": "setosa"}, {"sepalLength": 5.4, "sepalWidth": 3.7, "petalLength": 1.5, "petalWidth": 0.2, "species": "setosa"}, {"sepalLength": 5.4, "sepalWidth": 3.7, "petalLength": 1.5, "petalWidth": 0.2, "species": "setosa"}, {"sepalLength": 5.4, "sepalWidth": 3.7, "petalLength": 1.5, "petalWidth": 0.2, "species": "setosa"}, {"sepalLength": 5.4, "sepalWidth": 3.7, "petalLength": 5.5, "petalWidth": 0.2, "species": "setosa"}, {"sepalLength": 5.4, "sepalWidth": 3.7, "petalLength": 5.5, "petalWidth": 0.2, "species": "setosa"}, {"sepalLength": 5.4, "sepa
    {"sepalLength": 4.9, "sepalWidth": 3.0, "petalLength": 1.4, "petalWidth": 0.2, "species": "setosa"}, 
{"sepalLength": 4.7, "sepalWidth": 3.2, "petalLength": 1.5, "petalWidth": 0.2, "species": "setosa"}, 
{"sepalLength": 4.6, "sepalWidth": 3.1, "petalLength": 1.5, "petalWidth": 0.2, "species": "setosa"}, 
{"sepalLength": 5.0, "sepalWidth": 3.6, "petalLength": 1.4, "petalWidth": 0.2, "species": "setosa"}, 
{"sepalLength": 5.4, "sepalWidth": 3.9, "petalLength": 1.7, "petalWidth": 0.4, "species": "setosa"}, 
{"sepalLength": 5.0, "sepalWidth": 3.4, "petalLength": 1.4, "petalWidth": 0.3, "species": "setosa"}, 
{"sepalLength": 5.0, "sepalWidth": 3.4, "petalLength": 1.5, "petalWidth": 0.2, "species": "setosa"}, 
{"sepalLength": 4.4, "sepalWidth": 2.9, "petalLength": 1.4, "petalWidth": 0.2, "species": "setosa"}, 
{"sepalLength": 5.4, "sepalWidth": 3.7, "petalLength": 1.5, "petalWidth": 0.1, "species": "setosa"}, 
{"sepalLength": 4.8, "sepalWidth": 3.7, "petalLength": 1.5, "petalWidth": 0.2, "species": "setosa"}, 
{"sepalLength": 4.8, "sepalWidth": 3.0, "petalLength": 1.6, "petalWidth": 0.1, "species": "setosa"}, 
{"sepalLength": 4.8, "sepalWidth": 3.0, "petalLength": 1.1, "petalWidth": 0.1, "species": "setosa"}, 
rocessed a total of 15 messages
Processed a total of 15 messages
[student898_2@bigdataanalytics-worker-3 ~]$
                                          Запускаем `pyspark`
                                          export SPARK_KAFKA_VERSION=0.10
                                          /opt/spark-2.4.8/bin/pyspark --packages org.apache.spark:spark-sql-kafka-0-10 2.11:2.4.5 --
                                          driver-memory 512m --master local[1]
                                                                                                                                              student898_2@bigdataanalytics-worker-3:~ - Терминал
  Файл Правка Вид Терминал Вкладки Справка
                                           default
                                                                             | 6 | 0 | 0
 :: retrieving :: org.apache.spark#spark-submit-parent-07c4eaed-8f5f-460d-97ba-2a696c8f49a5
                      confs: [default]
                      O artifacts copied, 6 already retrieved (OkB/6ms)
22/01/21 17:22:05 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
Setting default log level to "WARN"
To adjūst logging level use sc.setLogLevel(newLevel). For SparkR, use setLogLevel(newLevel).
22/01/21 17:22:06 WARN util.Utils: Service 'SparkUI' could not bind on port 4040. Attempting port 4041.
Welcome to
       / _/ _ / _ / _ / _ / _ / _ / _ / version 2.4.8
Using Python version 2.7.5 (default, Nov 16 2020 22:23:17)
SparkSession available as 'spark'.
```

student898\_2@bigdataanalytics-worker-3:~ - Терминал

```
Далее делаем стандартные импорты и определяем константы, схему данных и сам стрим, который читает топик `shadrin_iris` из Кафки.

from pyspark.sql import functions as F

from pyspark.sql.types import StructType, StringType, FloatType

kafka_brokers = "bigdataanalytics-worker-3:6667"

raw_data = spark.readStream. \

format("kafka"). \
```

```
option("subscribe", "shadrin_iris"). \
                     option("startingOffsets", "earliest"). \
                     option("maxOffsetsPerTrigger", "6"). \
                     load()
               schema = StructType() \
                      .add("sepalLength", FloatType()) \
                      .add("sepalWidth", FloatType()) \
                      .add("petalLength", FloatType()) \
                      .add("petalWidth", FloatType()) \
                      .add("species", StringType())
                                                   student898_2@bigdataanalytics-worker-3:~ - Терминал
Файл Правка Вид Терминал Вкладки Справка
Using Python version 2.7.5 (default, Nov 16 2020 22:23:17)
SparkSession available as 'spark'
>>> from pyspark.sql import functions as F
>>> from pyspark.sql.types import StructType, StringType, FloatType
>>> kafka_brokers = "bigdataanalytics-worker-3:6667"
>>> raw_data = spark.readStream. \
        format("kafka"). \
        option("kafka.bootstrap.servers", kafka_brokers). \
option("subscribe", "shadrin_iris"). \
        option("startingOffsets", "earliest"). \
        option("maxOffsetsPerTrigger", "6"). \
        load()
>>> schema = StructType() \
       add("sepalLength", FloatType()) \
    .add("sepalWidth", FloatType()) \
    .add("petalLength", FloatType()) \
    .add("petalWidth", FloatType()) \
```

option("kafka.bootstrap.servers", kafka\_brokers). \

## WATERMARK и дубликаты внутри одного батча.

. . .

. . .

. . .

. . .

. . . . . . . . . . . .

>>>

.add("species", StringType())

Waterwark - одна из настроек стрима для сохранения состояния этого стрима внутри чекпойнта. Добавим колонку с временем обработки микробатча. Она понадобится для настройки чекпойнта и вотермарки.

```
extended_iris = raw_data \
    .select(F.from_json(F.col("value").cast("String"), schema).alias("value"),
"offset") \
    .select("value.*", "offset") \
```

```
.withColumn("receive_time", F.current_timestamp())
            extended_iris.printSchema()
                                         student898_2@bigdataanalytics-worker-3:~ - Терминал
Файл Правка Вид Терминал Вкладки Справка
>>> extended_iris = raw_data \
      .select(F.from_json(F.col("value").cast("String"), schema).alias("value"), "offset") \
      .select("value.*", "offset") \
      .withColumn("receive_time", F.current_timestamp())
>>> extended_iris.printSchema()
|-- sepalLength: float (nullable = true)
|-- sepalWidth: float (nullable = true)
 |-- petalLength: float (nullable = true)
 |-- petalWidth: float (nullable = true)
|-- species: string (nullable = true)
 |-- offset: long (nullable = true)
|-- receive_time: timestamp (nullable = false)
            В методе `console_output` обязательно указываем папку, в которой будет
            храниться чекпойнт.
            def console output(df, freq):
                 return df.writeStream \
                      .format("console") \
                      .trigger(processingTime='%s seconds' % freq ) \
                      .option("checkpointLocation", "checkpoints/duplicates console chk") \
                      .options(truncate=False) \
                      .start()
                                         student898_2@bigdataanalytics-worker-3:~ - Терминал
Файл Правка Вид Терминал Вкладки Справка
>>> def console_output(df, freq):
      return df.writeStream \
         .format("console") \
          .trigger(processingTime='%s seconds' % freq ) \
         .option("checkpointLocation", "checkpoints/duplicates_console_chk") \
          .options(truncate=False) \
            Запускаем стрим и смотрим как растёт наш чекпойнт (команда `hdfs dfs -du -h
            checkpoints/duplicates_console_chk`).
            stream = console output(extended iris , 5)
            stream.stop()
```

. . .

. . .

. . .

. . .

. . . . . .

```
student898_2@bigdataanalytics-worker-3:~ - Терминал
Файл Правка Вид Терминал Вкладки Справка
Batch: 1
|sepalLength|sepalWidth|petalLength|petalWidth|species|offset|receive\_time|\\
                     1.7
15.4
          13.9
                                10.4
                                                       [2022-01-21 17:28:57.352]
                                          Isetosa 16
          | 3.4 | 1.4 | 1.5 | 2.9 | 1.4 | 3.1 | 1.5 | 3.7 | 1.5 |
14.6
                               0.3
                                          setosa | 7
                                                        12022-01-21 17:28:57.352
                               0.2
15.0
                                          |setosa |8
                                                       |2022-01-21 17:28:57.352
4.4
                                          |setosa |9
                                                        |2022-01-21 17:28:57.352
                                          |setosa |10
14.9
                               0.1
                                                       2022-01-21 17:28:57.352
                                          Isetosa | 11
                                                       [2022-01-21 17:28:57.352]
15.4
                                10.2
Batch: 2
|sepalLength|sepalWidth|petalLength|petalWidth|species|offset|receive_time
                 4.8
          3.4
          3.0
3.0
4.8
14.3
5.8
5.7
          4.4
İ5.4
          İ3.9
stream.stop()
>>> stream.stop()
```

Задаём вотермарку, которая должна очищать чекпоинт. Первый параметр - назване колонки, на которую смотрит вотермарка, второй параметр - гарантированное время жизни информации о сообщении в чекпойнте. Именно для этого мы добавляли столбец `receive\_time`.

waterwarked\_iris = extended\_iris.withWatermark("receive\_time", "30 seconds")

waterwarked iris.printSchema()

|-- receive\_time: timestamp (nullable = false)

```
student898_2@bigdataanalytics-worker-3:~-Терминал — + ×

Файл Правка Вид Терминал Вкладки Справка

>>> waterwarked_iris = extended_iris.withWatermark("receive_time", "30 seconds")

>>> waterwarked_iris.printSchema()

root

|-- sepalLength: float (nullable = true)
|-- petalLength: float (nullable = true)
|-- petalLength: float (nullable = true)
|-- petalWidth: float (nullable = true)
|-- sepecies: string (nullable = true)
|-- offset: long (nullable = true)
```

Схема не поменялась. Вотермарка только следит за чекпойнтом, но никак не аффектит наши данные.

Теперь данные можно проверить на наличие дубликатов. Дубли проверяем по двум колонкам: `species` и `receive\_time`. Таким образом будут отсеиваться дубли по полю `species` внутри одного микробатча, так как столбец `receive\_time` для всех записей внутри этого микробатча одинаковый.

```
deduplicated_iris = waterwarked_iris.drop_duplicates(["species",
"receive_time"])
```

```
Чтобы всё заработало, надо во 2 терминале очистить чекпойнт
           hdfs dfs -rm -r checkpoints/duplicates console chk
           stream = console_output(deduplicated_iris , 20)
           stream.stop()
                                       student898_2@bigdataanalytics-worker-3:~ - Терминал
Файл Правка Вид Терминал Вкладки Справка
|sepalLength|sepalWidth|petalLength|petalWidth|species|offset|receive_time
|null |null |null |null |0 |2022-01-21 17:34:43.259|
|5.1 |3.5 |1.4 |0.2 |setosa |1 |2022-01-21 17:34:43.259|
|sepalLength|sepalWidth|petalLength|petalWidth|species|offset|receive_time
                 1.7
                          0.4
                                     |setosa |6 | 2022-01-21 17:35:00.004|
[Stage 8:=====>
                                                    (34 + 1) / 200]
           Без указания в `drop_duplicates` столбца с временнОй меткой, дубликаты
           отсеивались бы по всем данным. И все эти данные хранились бы в чекпойнте, даже
           не смотря на то что у нас настроена вотермарка. Чтобы не допустить раздувания
            чекпойнта, указывается столбец с временнОй меткой. Вотермарка ограничивает
            "глубину" данных не только для поиска дубликатов, но и для любой группирующей
           функции.
           1\.5\. WINDOW и дубликаты за периоды времени.
           Создаём временное окно. В структуру датафрейма добавился новый столбец.
           windowed_iris = extended_iris.withColumn("window_time",
           F.window(F.col("receive time"), "2 minutes"))
           windowed_iris.printSchema()
                                       student898_2@bigdataanalytics-worker-3:~ - Терминал
Файл Правка Вид Терминал Вкладки Справка
>>> windowed_iris = extended_iris.withColumn("window_time", F.window(F.col("receive_time"), "2 minutes"))
>>> windowed_iris.printSchema()
|-- sepalLength: float (nullable = true)
|-- sepalWidth: float (nullable = true)
|-- petalLength: float (nullable = true)
|-- petalWidth: float (nullable = true)
```

Batch: 0

Batch: 1

root

|-- species: string (nullable = true) |-- offset: long (nullable = true)

|-- receive time: timestamp (nullable = false) |-- window\_time: struct (nullable = false) |-- start: timestamp (nullable = true) |-- end: timestamp (nullable = true)

Видим что в рамках одного окна дубликатов нет.

## 1\.6\. SLIDING WINDOW

stream.stop()
>>> stream.stop()

Аналогично предыдущему пункту создаём дополнительное поле `sliding\_time`. В функции `F.window` первый аргумент это колонка (временная метка), по которой создаётся окно; второй аргумент - ширина окна; третий - сдвиг окна. Добавляем вотермарку и указываем колонки, по которым будем исключать дубли.

```
sliding_iris = extended_iris.withColumn("sliding_time",
                F.window(F.col("receive_time"), "1 minute", "30 seconds"))
                waterwarked_sliding_iris = sliding_iris.withWatermark("sliding_time", "2
                minutes")
                deduplicated_sliding_iris =
                waterwarked_sliding_iris.drop_duplicates(["species", "sliding_time"])
                deduplicated_sliding_iris.printSchema()
                                                       student898_2@bigdataanalytics-worker-3:~ - Терминал
Файл Правка Вид Терминал Вкладки Справка
>>> sliding_iris = extended_iris.withColumn("sliding_time", F.window(F.col("receive_time"), "1 minute", "30 seconds"))
>>> waterwarked_sliding_iris = sliding_iris.withWatermark("sliding_time", "2 minutes")
>>> deduplicated_sliding_iris = waterwarked_sliding_iris.drop_duplicates(["species", "sliding_time"])
>>> deduplicated_sliding_iris.printSchema()
 |-- sepalLength: float (nullable = true)
 |-- sepalWidth: float (nullable = true)
|-- petalLength: float (nullable = true)
 |-- petalWidth: float (nullable = true)
 |-- species: string (nullable = true)
 |-- offset: long (nullable = true)
|-- receive_time: timestamp (nullable = false)
 |-- sliding_time: struct (nullable = true)
|-- start: timestamp (nullable = true)
      |-- end: timestamp (nullable = true)
```

```
stream = console output(deduplicated sliding iris , 10)
stream.stop()
```

root

student898\_2@bigdataanalytics-worker-3:~ - Терминал

```
Тут так же видим что в рамках каждого окна нет дубликатов. В третьем миробатче хорошо видно, как одна и та же запись с `offset = 19` является новой для обоих окон 19:49:30 - 19:50:30` и 19:50:00 - 19:51:00`.
```

## 1\.7\. OUTPUT MODES - считаем суммы

Переопределяем метод `console\_output` так, чтобы можно было задавать режим вывода результата работы аггрегационных функций.

```
def console_output(df, freq, out_mode):
    return df.writeStream.format("console") \
        .trigger(processingTime='%s seconds' % freq ) \
        .options(truncate=False) \
        .option("checkpointLocation", "checkpoints/watermark_console_chk2") \
        .outputMode(out mode) \
```

```
.start()
          Используем ранее созданный датафрейм с вотермаркой на 2 минуты. Группируем
          данные по нескользящему окну `window_time`.
          count_iris = waterwarked_windowed_iris.groupBy("window_time").count()
          Перед каждым запуском очищаем чекпойнт командой `hdfs dfs -rm -r
          checkpoints/watermark_console_chk2`.
          ##### update
          stream = console output(count iris , 10, "update")
          stream.stop()
                                   student898_2@bigdataanalytics-worker-3:~ - Терминал
Файл Правка Вид Терминал Вкладки Справка
|[2022-01-21 17:50:00, 2022-01-21 17:52:00]|6 |
22/01/21 17:51:46 WARN streaming.ProcessingTimeExecutor: Current batch is falling behind. The trigger interval is 10000 milliseconds, but spent 10016
milliseconds
|[2022-01-21 17:50:00, 2022-01-21 17:52:00]|12 |
|window_time
[2022-01-21 17:50:00, 2022-01-21 17:52:00]|18
_____
+-----+
|window_time
                              count
|[2022-01-21 17:52:00, 2022-01-21 17:54:00]|6 |
+-----+
lwindow time
                         | Lcount |
|[2022-01-21 17:52:00, 2022-01-21 17:54:00]|12 |
```

В режиме `.outputMode("update")` в консоль пишутся только обновляющиеся записи. Считатся `count` по каждому окну и выводятся записи только о тех окнах, в которых значение поменялось.

##### complete

Batch: 2

Batch: 3

Batch: 4

stream.stop() >>> stream.stop()

>>>

```
stream = console_output(count_iris , 10, "complete")
stream.stop()

###### append

Пишем все записи только один раз. Информация выводится один раз, когда окно заканчивается.
```

```
stream = console_output(count_iris , 10, "append")
           stream.stop()
           Тут не увидел результата все батчи пустые. Скорее всего данный режим не
           поддерживается для данной аггрегирующей функции.
           1\.8\. Наблюдаем за суммами в плавающем окне.
                                      student898_2@bigdataanalytics-worker-3:~ - Терминал
Файл Правка Вид Терминал Вкладки Справка
|sliding_time
|[2022-01-21 17:58:00, 2022-01-21 17:59:00]|6
[2022-01-21 17:57:30, 2022-01-21 17:58:30]|6
22/01/21 17:58:22 WARN streaming.ProcessingTimeExecutor: Current batch is falling behind. The trigger interval is 10000 milliseconds, but spent 15671
|sliding_time
                                 Icountl
|[2022-01-21 17:58:00, 2022-01-21 17:59:00]|12
|[2022-01-21 17:57:30, 2022-01-21 17:58:30]|12
.....
+-----+
|sliding_time
             |count|
|[2022-01-21 17:58:00, 2022-01-21 17:59:00]|18
|[2022-01-21 17:58:30, 2022-01-21 17:59:30]|6
|sliding_time
|[2022-01-21 17:58:00, 2022-01-21 17:59:00]|24 |
[2022-01-21 17:58:30, 2022-01-21 17:59:30] 12
|sliding time
|[2022-01-21 17:58:00, 2022-01-21 17:59:00]|30
[2022-01-21 17:58:30, 2022-01-21 17:59:30] 18
stream.stop()
>>> stream.stop()
           sliding iris = waterwarked sliding iris.groupBy("sliding time").count()
           stream = console_output(sliding_iris , 10, "update")
```

query.

Batch: 14

Batch: 15

Batch: 16

Batch: 17

stream.stop()

```
##### Задание 2. Сджойнить стрим со статикой.
            Создадим статический датафрейм, который будет расширять исходный датасет
            ирисов.
            static_df_schema = StructType() \
                 .add("species", StringType()) \
                 .add("description", StringType())
            static_df_data = (
                 ("setosa", "Iris setosa has a deep violet blue flower. The sepals are
            deeply-veined dark purple with a yellow-white signal."),
                 ("versicolor", "Iris versicolor is a flowering herbaceous perennial plant,
            growing 10-80 cm high. The well developed blue flower has 6 petals and sepals
            spread out nearly flat and have two forms."),
                 ("virginica", "Iris virginica is a perennial plant. The plant has 2 to 4
            erect or arching, bright green, lance-shaped leaves that are flattened into one
            plane at the base.")
            static df = spark.createDataFrame(static df data, static df schema)
            static joined = waterwarked iris.join(static df, "species", "left")
            static joined.isStreaming
                                        student898_2@bigdataanalytics-worker-3:~ - Терминал
Файл Правка Вид Терминал Вкладки Справка
>>> static_df_schema = StructType() \
      .add("species", StringType())
      .add("description", StringType())
>>> static_df_data = (
     ("setosa", "Iris setosa has a deep violet blue flower. The sepals are deeply-veined dark purple with a yellow-white signal."),
      ("versicolor", "Iris versicolor is a flowering herbaceous perennial plant, growing 10-80 cm high. The well developed blue flower has 6 petals
and sepals spread out nearly flat and have two forms."),
      ("virginica", "Iris virginica is a perennial plant. The plant has 2 to 4 erect or arching, bright green, lance-shaped leaves that are flattene
d into one plane at the base.")
>>> static_df = spark.createDataFrame(static_df_data, static_df_schema)
>>> static_joined = waterwarked_iris.join(static_df, "species", "left")
>>> static_joined.isStreaming
```

Наблюдаем только обновляющиеся записи в каждом плавающем окне.

. . .

. . .

True

После джойна стрима со статикой получаем стрим. static\_joined.printSchema()

```
▼ student898_2@bigdataanalytics-worker-3:~-Терминал — + ×
Файл Правка Вид Терминал Вкладки Справка

>>> static_joined.printSchema()
root
|-- species: string (nullable = true)
|-- sepalLength: float (nullable = true)
|-- petalLength: float (nullable = true)
|-- petalLength: float (nullable = true)
|-- petalWidth: float (nullable = true)
|-- offset: long (nullable = true)
|-- receive_time: timestamp (nullable = false)
|-- description: string (nullable = true)
```

```
Добавлась колонка `description`.

stream = console_output(static_joined , 10, "update")

stream.stop()
```

```
Batch: 20
|species |sepalLength|sepalWidth|petalLength|petalWidth|offset|receive_time
                                                                                   Idescription
```

12.2 |5.0 11.5 120 |2022-01-21 18:04:10.003|Iris virginica is a perennial plant. The plant has 2 to 4 erec |virginica|6.0 t or arching, bright green, lance-shaped leaves that are flattened into one plane at the base. |virginica|6.9 |3.2 |5.7 2.3 |121 |2022-01-21 18:04:10.003|Iris virginica is a perennial plant. The plant has 2 to 4 erec t or arching, bright green, lance-shaped leaves that are flattened into one plane at the base.

12.8 4.9 12.0 122 |2022-01-21 18:04:10.003|Iris virginica is a perennial plant. The plant has 2 to 4 erec t or arching, bright green, lance-shaped leaves that are flattened into one plane at the base. 12.8 6.7 2.0 |123 |2022-01-21 18:04:10.003|Iris virginica is a perennial plant. The plant has 2 to 4 erec t or arching, bright green, lance-shaped leaves that are flattened into one plane at the base. |2022-01-21 18:04:10.003|Iris virginica is a perennial plant. The plant has 2 to 4 erec 12.7 4.9 11.8 124

|virginica|6.3 t or arching, bright green, lance-shaped leaves that are flattened into one plane at the base. |virginica|6.7 |5.7<sup>'</sup> 3.3 2.1 |125 |2022-01-21 18:04:10.003|Iris virginica is a perennial plant. The plant has 2 to 4 erec

t or arching, bright green, lance-shaped leaves that are flattened into one plane at the base.|

stream.stop() >>> stream.stop()

|virginica|5.6

|virginica|7.7

##### Задание 3. Сджойнить стрим со стримом.

Это задание сделаем на примере датасетов товаров и заказов.

Датасет, соотносящий товары и заказы читаем из кафки, топик `order items`.

raw\_orders\_items = spark.readStream. \

```
format("kafka"). \
    option("kafka.bootstrap.servers", kafka brokers). \
    option("subscribe", "order_items"). \
    option("startingOffsets", "earliest"). \
   load()
Разбираем value и добавляем окно.
schema_orders_items = StructType() \
    .add("order_id", StringType()) \
    .add("order_item_id", StringType()) \
    .add("product_id", StringType()) \
    .add("seller_id", StringType()) \
    .add("shipping limit date", StringType()) \
    .add("price", StringType()) \
    .add("freight value", StringType())
extended_orders_items = raw_orders_items \
    .select(F.from json(F.col("value").cast("String"),
schema orders items).alias("value")) \
    .select("value.*") \
    .withColumn("order_items_receive_time", F.current_timestamp()) \
    .withColumn("window time",F.window(F.col("order items receive time"),"2
minutes"))
extended orders items.printSchema()
```

```
Датасет списка заказов читаем из кафки, топик `orders_json`.

raw_orders = spark.readStream. \

format("kafka"). \

option("kafka.bootstrap.servers", kafka_brokers). \

option("subscribe", "orders_json"). \

option("maxOffsetsPerTrigger", "5"). \

option("startingOffsets", "earliest"). \

load()

Pазбираем value, добавляем колонку со временем получения сообщения,создаём по ней окно и добавляем вотермарку.

schema = StructType() \

.add("order_id", StringType()) \

.add("customer id", StringType()) \
```

```
.add("order_status", StringType()) \
    .add("order_purchase_timestamp", StringType()) \
    .add("order_approved_at", StringType()) \
    .add("order_delivered_carrier_date", StringType()) \
    .add("order_delivered_customer_date", StringType()) \
    .add("order_estimated_delivery_date", StringType())
waterwarked_windowed_orders = raw_orders \
    .select(F.from_json(F.col("value").cast("String"), schema).alias("value"),
"offset") \
    .select("value.order_id", "value.order_status",
"value.order_purchase_timestamp") \
    .withColumn("order receive time", F.current timestamp()) \
    .withColumn("window time",F.window(F.col("order receive time"),"2
minutes")) \
    .withWatermark("window_time", "2 minutes")
waterwarked_windowed_orders.printSchema()
```

```
Делаем джойн двух датасетов.

streams_joined = waterwarked_windowed_orders \
    .join(extended_orders_items, ["order_id", "window_time"] , "inner") \
    .select("order_id", "order_item_id", "product_id", "window_time")

Тип отображения `update`не подходит для `inner` джойна.

Очищаем чекпоитс

stream = console_output(streams_joined , 10, "append")

stream.stop()
```

Здесь не увидел результата, так как в топике `order items` не было данных. По факту этот топик вычитывается целиком за раз, поэтому в первом окне можно наблюдать микробатчи сджойненого датасета. Для остальных окон микробатчи пустые, так как `window time` уже различаются. Из топика `order items` новые данные не приходят.

+------+

Написать скрипт на python для конвертации файла csv в json.

```
import csv
import json
with open('test.csv') as f:
    reader = csv.DictReader(f)
    rows = list(reader)
```

```
with open('test.json', 'w') as f:
    json.dump(rows, f)
```