# 5. Spark Streaming. Stateful streams

Загрузить в топик kafka свои данные, прочитать их в потоке, применить watermark и window. Повторить шаги выполненные на занятии.

Дополнительно, объединить статичный и динамичный потоки. Задание на повышенный бал: Написать скрипт на python для конвертации файла csv в json.

Подключаемся и проверяем, что файл data.csv загрузился.

ssh -i ~/.ssh/id\_rsa\_student898\_2 <u>student898\_2@37.139.41.176</u>

ls for\_stream

```
▼ student898_2@bigdataanalytics-worker-3:~-Терминал — + ×
Файл Правка Вид Терминал Вкладки Справка

[student898_2@bigdataanalytics-worker-3 ~]$ ls for_stream
archive.csv data.json drake_data.json iris.json product_list2.csv product_list4.csv
data.csv dataset.csv file1.json product_list1.csv product_list3.csv product_list.csv
[student898_2@bigdataanalytics-worker-3 ~]$ ■
```

## less for stream/data.csv

```
    student898_2@bigdataanalytics-worker-3:~ - Терминал

    Файл Правка Вид Терминал Вкладки Справка

    "time_id", "ping_ms", "temperature_c", "humidity_p"

    "2021-09-30 21:08:02", "17.28", "25", "35"

    "2021-09-30 21:10:01", "18.59", "22", "40"

    "2021-09-30 21:12:02", "16.73", "22", "42"

    "2021-09-30 21:13:02", "18.12", "22", "42"

    "2021-09-30 21:14:01", "18.21", "22", "43"

    "2021-09-30 21:15:01", "17.92", "22", "43"

    "2021-09-30 21:16:02", "17.2", "22", "43"

    "2021-09-30 21:16:02", "17.2", "22", "43"

    "2021-09-30 21:16:02", "17.2", "22", "43"
```

### смотрим лист топиков

/usr/hdp/current/kafka-broker/bin/kafka-topics.sh --zookeeper bigdataanalytics-worker-3:2181 -- list

```
student898_2@bigdataanalytics-worker-3:~ - Терминал
Файл Правка Вид Терминал Вкладки Справка
shadrin iris
shadrin iris pikalev
shadrin_iris_sink
st lesson2
student559-12-json
student559 12
student559 8 lesson2
student559 8 lesson3
test-lesson2
test_lesson2
test_lesson2_1
test lesson 2 sapr
tolstykov les4
tolstykov_les4_sink
```

Создаю топик tolstykov les5

[student898\_2@bigdataanalytics-worker-3 ~]\$

/usr/hdp/current/kafka-broker/bin/kafka-topics.sh --create --topic tolstykov\_les5 --zookeeper bigdataanalytics-worker-3:2181 --partitions 1 --replication-factor 1

```
student898_2@bigdataanalytics-worker-3:~ - Терминал
               Вид Терминал Вкладки Справка
[student898_2@bigdataanalytics-worker-3 ~]$ /usr/hdp/current/kafka-broker/bin/kafka-topics.sh --create --topic tolstykov_les5 --zookeeper bigdataanaly
tics-worker-3:2181 --partitions 1 --replication-factor 1
WARNING: Due to limitations in metric names, topics with a period ('.') or underscore ('_') could collide. To avoid issues it is best to use either, b
ut not both.
Created topic "tolstykov_les5".
[student898_2@bigdataanalytics-worker-3 ~]$ /usr/hdp/current/kafka-broker/bin/kafka-topics.sh --zookeeper bigdataanalytics-worker-3:2181 --list
             Загрузить файл в топик
             /usr/hdp/current/kafka-broker/bin/kafka-console-producer.sh --broker-list bigdataanalytics-
             worker-3:6667 --topic tolstykov les5 < for stream/data.csv
                                              student898_2@bigdataanalytics-worker-3:~ - Терминал
Файл
      Правка Вид Терминал Вкладки
                                        Справка
2@bigdataanalytics-worker-3 ~]$
             Прочитать топик tolstykov_les5
             /usr/hdp/current/kafka-broker/bin/kafka-console-consumer.sh --topic tolstykov les5 --from-
             beginning --bootstrap-server bigdataanalytics-worker-3:6667 --max-messages 10
                                              student898_2@bigdataanalytics-worker-3:~ - Терминал
Файл Правка Вид Терминал Вкладки Справка
"time_id","ping_ms","temperature_c","humidity_p"
"2021-09-30 21:08:02","17.28","25","35"
"2021-09-30 21:09:02","17.73","23","40"
"2021-09-30 21:10:01","18.59","22","41"
"2021-09-30 21:10:01","18.59","22","41"
"2021-09-30 21:12:02","16.73","22","42"
"2021-09-30 21:13:02","18.12","22","43"
"2021-09-30 21:14:01","18.21","22","43"
"2021-09-30 21:15:01","17.92","22","43"
"2021-09-30 21:16:02","17.2","22","43"
"2021-09-30 21:17:02","18.16","22","43"
Processed a total of 10 messages
[student898_2@bigdataanalytics-worker-3 ~]$
             Запускаем `pyspark`
             export SPARK_KAFKA_VERSION=0.10
             /opt/spark-2.4.8/bin/pyspark --packages org.apache.spark:spark-sql-kafka-0-10_2.11:2.4.5 --
             driver-memory 512m --master local[1]
```

```
from pyspark.sql import functions as F
from pyspark.sql.types import StructType, StringType, FloatType
kafka_brokers = "bigdataanalytics-worker-3:6667"
raw_data = spark.readStream. \
    format("kafka"). \
    option("kafka.bootstrap.servers", kafka_brokers). \
    option("subscribe", "tolstykov_les5"). \
    option("startingOffsets", "earliest"). \
    option("maxOffsetsPerTrigger", "6"). \
    load()
Определяем схему данных нашего исходного датасета.
schema = StructType() \
     .add("time_id", StringType()) \
     .add("ping_ms", StringType()) \
     .add("temperature_c", StringType()) \
     .add("humidity_p", StringType())
def console_output(df, freq):
    return df.writeStream \
```

```
.format("console") \
                                             .trigger(processingTime='%s seconds' % freq ) \
                                             .options(truncate=False) \
                                             .start()
                                                                                 student898_2@bigdataanalytics-worker-3:~ - Терминал
Файл Правка Вид Терминал Вкладки Справка
>>> from pyspark.sql import functions as F
>>> from pyspark.sql.types import StructType, StringType, FloatType
>>> kafka_brokers = "bigdataanalytics-worker-3:6667"
>>> raw_data = spark.readStream. \
             format("kafka").
           option("kafka.bootstrap.servers", kafka_brokers). \
option("subscribe", "tolstykov_les5"). \
option("startingOffsets", "earliest"). \
carliest"

carliest"

rigger", "6").

time_id", StringType()) \
.add("ping_ms", StringType()) \
.add("temperature_c", StringType()) \
.add("humidity_p", StringType())

symbols

return_df.writeStream \
.format("console")
.trigger(proc.
.option
            option("maxOffsetsPerTrigger", "6"). \
                   .trigger(processingTime='%s seconds' % freq ) \
```

. . .

. . . ...

```
Сделаем преобразование в плоскую структуру
parsed data = raw data \
      .select(F.from_json(F.col("value").cast("String"), schema).alias("value"), "offset") \
      .select("value.*", "offset")
out = console_output(raw_data, 10)
out.stop()
```

```
Файл Правка Вид Терминал Вкладки Справка
|null||22 74 69 6D 65 5F 69 64 22 2C 22 70 69 6E 67 5F 6D 73 22 2C 22 74 65 6D 70 65 72 61 74 75 72 65 5F 63 22 2C 22 68 75 6D 69 64 69 74 79 5F 70 22
]|tolstykov_les5|0
                       10
                               |2022-01-24 18:24:41.358|0
|null|[22 32 30 32 31 2D 30 39 2D 33 30 20 32 31 3A 30 38 3A 30 32 22 2C 22 31 37 2E 32 38 22 2C 22 32 35 22 2C 22 33 35 22]
|tolstykov_les5|0
                        11
                               |2022-01-24 18:24:41.364|0
|null|[22 32 30 32 31 2D 30 39 2D 33 30 20 32 31 3A 30 39 3A 30 32 22 2C 22 31 37 2E 37 33 22 2C 22 32 33 22 2C 22 34 30 22]
                               |2022-01-24 18:24:41.364|0
                       12
|tolstykov les5|0
|null|[22 32 30 32 31 2D 30 39 2D 33 30 20 32 31 3A 31 30 3A 30 31 22 2C 22 31 38 2E 35 39 22 2C 22 32 32 22 2C 22 34 31 22]
|tolstvkov les5|0
                        13
                               |2022-01-24 18:24:41.365|0
|null|[22 32 30 32 31 2D 30 39 2D 33 30 20 32 31 3A 31 32 3A 30 32 22 2C 22 31 36 2E 37 33 22 2C 22 32 32 22 2C 22 34 32 22]
                      14
                               |2022-01-24 18:24:41.365|0
Itolstvkov les510
|null||22 32 30 32 31 2D 30 39 2D 33 30 20 32 31 3A 31 33 3A 30 32 22 2C 22 31 38 2E 31 32 22 2C 22 32 32 22 2C 22 34 32 22
|tolstykov_les5|0 |5 |2022-01-24 18:24:41.365|0
Batch: 1
|key |value
                                                                                                                         Itopic
                                                                                                                                        |partition|
offset|timestamp
                            |timestampTvpe|
|null||[22 32 30 32 31 2D 30 39 2D 33 30 20 32 31 3A 31 34 3A 30 31 22 2C 22 31 38 2E 32 31 22 2C 22 32 32 22 2C 22 34 33 22]|tolstykov_les5|0
     |2022-01-24 18:24:41.365|0
|null|[22 32 30 32 31 2D 30 39 2D 33 30 20 32 31 3A 31 35 3A 30 31 22 2C 22 31 37 2E 39 32 22 2C 22 32 32 22 2C 22 34 33 22]|tolstykov les5|0
      |2022-01-24 18:24:41.365|0
|null||22 32 30 32 31 2D 30 39 2D 33 30 20 32 31 3A 31 36 3A 30 32 22 2C 22 31 37 2E 32 22 2C 22 32 32 22 2C 22 34 33 22] |tolstykov_les5|0
      |2022-01-24 18:24:41.365|0
|null|[22 32 30 32 31 2D 30 39 2D 33 30 20 32 31 3A 31 37 3A 30 32 22 2C 22 31 38 2E 31 36 22 2C 22 32 32 22 2C 22 34 33 22]|tolstykov_les5|0
      |2022-01-24 18:24:41.365|0
|null||[22 32 30 32 31 2D 30 39 2D 33 30 20 32 31 3A 31 38 3A 30 32 22 2C 22 32 31 2E 33 35 22 2C 22 32 32 2C 22 34 32 22]|tolstykov_les5|0
      |2022-01-24 18:24:41.365|0
|null|[22 32 30 32 31 2D 30 39 2D 33 30 20 32 31 3A 31 39 3A 30 31 22 2C 22 31 37 2E 33 31 22 2C 22 32 32 22 2C 22 34 33 22]|tolstykov les5|0
   |2022-01-24 18:24:41.365|0
out.stop()
>>> out.stop()
```

student898\_2@bigdataanalytics-worker-3:~ - Терминал

```
extended_data = raw_data \
    .select(F.from_json(F.col("value").cast("String"), schema).alias("value"),
"offset") \
    .select("value.*", "offset") \
    .withColumn("receive_time", F.current_timestamp())

extended_data.printSchema()

def console_output(df, freq):
    return df.writeStream \
        .format("console") \
        .trigger(processingTime='%s seconds' % freq ) \
        .option("checkpointLocation", "checkpoints/duplicates_console_chk") \
```

```
.start()
                                                     student898_2@bigdataanalytics-worker-3:~ - Терминал
Файл Правка Вид Терминал Вкладки Справка
>>> extended data = raw data \
       .select(F.from_json(F.col("value").cast("String"), schema).alias("value"), "offset") \
.select("value.*", "offset") \
. . .
        .withColumn("receive_time", F.current_timestamp())
>>> extended data.printSchema()
root
 |-- time_id: string (nullable = true)
 |-- ping_ms: string (nullable = true)
 |-- temperature_c: string (nullable = true)
 |-- humidity_p: string (nullable = true)
|-- offset: long (nullable = true)
 |-- receive_time: timestamp (nullable = false)
>>> def console_output(df, freq):
        return df.writeStream
             .format("console")
             .trigger(processingTime='%s seconds' % freq ) \
            .option("checkpointLocation", "checkpoints/duplicates_console_chk") \
             .options(truncate=False) \
            .start()
>>>
               Подключаемся в другом окне, удаляем checkpoints
               hdfs dfs -rm -f -r checkpoints
               hdfs dfs -ls
                                                     student898_2@bigdataanalytics-worker-3:~ - Терминал
Файл Правка Вид Терминал Вкладки Справка
  student898_2@bigdataanalytics-worker-3:~
                                                                                     student898_2@bigdataanalytics-worker-3:~
[student898_2@bigdataanalytics-worker-3 ~]$ hdfs dfs -rm -f -r checkpoints
22/01/24 18:35:58 INFO fs.TrashPolicyDefault: Moved: 'hdfs://bigdataanalytics-head-0.mcs.local:8020/user/student898_2/checkpoints' to trash at: hdfs:/
/bigdataanalytics-head-0.mcs.local:8020/user/student898_2/.Trash/Current/user/student898_2/checkpoints
[student898_2@bigdataanalytics-worker-3 ~]$ hdfs dfs -ls
Found 9 items
                                                     0 2022-01-24 18:35 .Trash
0 2022-01-20 19:25 .sparkStaging
drwx-----
              - student898 2 student898 2
drwxr-xr-x - student898_2 student898_2
drwxr-xr-x
             - student898 2 student898 2
                                                      0 2021-12-15 22:13 for stream
             - student898 2 student898 2
                                                      0 2022-01-22 22:34 input_csv_for_stream
drwxr-xr-x
                                                     0 2022-01-23 19:15 my_parquet sink
0 2022-01-23 19:13 shadrin_iris_file_checkpoint
drwxr-xr-x
             - student898 2 student898 2
             - student898_2 student898_2
drwxr-xr-x
drwxr-xr-x
             - student898_2 student898_2
                                                      0 2022-01-23 19:36 shadrin iris kafka checkpoint
             - student898 2 student898 2
                                                      0 2022-01-22 22:56 tolstykov_les4_file_checkpoint
drwxr-xr-x
drwxr-xr-x
              - student898 2 student898 2
                                                      0 2022-01-22 23:03 tolstykov les4 kafka checkpoint
[student898_2@bigdataanalytics-worker-3 ~]$
               В первом окне запускаем
               stream = console_output(extended_data , 5)
               stream.stop()
               Во втором окне наблюдаем
               hdfs dfs -du -h checkpoints/duplicates console chk
```

.options(truncate=False) \

```
Файл
     Правка Вид Терминал Вкладки
                                   Справка
                                   0 2022-01-22 22:56 tolstykov les4 file checkpoint
drwxr-xr-x - student898 2 student898 2
                                        0 2022-01-22 23:03 tolstykov les4 kafka checkpoint
drwxr-xr-x - student898 2 student898 2
[student898 2@bigdataanalytics-worker-3 ~]$ hdfs dfs -du -h checkpoints/duplicates console chk
87 174 checkpoints/duplicates_console_chk/commits
    90 checkpoints/duplicates console chk/metadata
45
1.3 K 2.5 K checkpoints/duplicates console_chk/offsets
30 60 checkpoints/duplicates console chk/sources
[student898 2@bigdataanalytics-worker-3 ~]$ hdfs dfs -du -h checkpoints/duplicates console chk
174 348 checkpoints/duplicates console chk/commits
          checkpoints/duplicates console chk/metadata
45
     90
2.5 K 5.1 K checkpoints/duplicates_console_chk/offsets
30 60 checkpoints/duplicates_console_chk/sources
[student898_2@bigdataanalytics-worker-3 ~]$ hdfs dfs -du -h checkpoints/duplicates_console_chk
203 406 checkpoints/duplicates console chk/commits
     90 checkpoints/duplicates_console_chk/metadata
45
3.4 K 6.8 K checkpoints/duplicates_console_chk/offsets
30 60
           checkpoints/duplicates_console_chk/sources
[student898_2@bigdataanalytics-worker-3 ~]$
Файл Правка Вид Терминал Вкладки Справка
|time_id|ping_ms|temperature_c|humidity_p|offset|receive_time
|null |null |null |42 |2022-01-24 18:39:10.004|

|null |null |null |43 |2022-01-24 18:39:10.004|

|null |null |null |44 |2022-01-24 18:39:10.004|

|null |null |null |null |45 |2022-01-24 18:39:10.004|

|null |null |null |null |46 |2022-01-24 18:39:10.004|

|null |null |null |null |47 |2022-01-24 18:39:10.004|
+----+
Ratch: 8
+-----+
|time_id|ping_ms|temperature_c|humidity_p|offset|receive_time
÷-----+----+
stream = c.stop()
>>> stream.stop()
>>>
```

student898\_2@bigdataanalytics-worker-3:~ - Терминал

#### Данные не читаются

Задаём вотермарку, которая должна очищать чекпоинт. Первый параметр - назване колонки, на которую смотрит вотермарка, второй параметр - гарантированное время жизни информации о сообщении в чекпойнте. Именно для этого мы добавляли столбец `receive\_time`.

waterwarked\_data = extended\_data.withWatermark("receive\_time", "30 seconds")

```
extended data.printSchema()
                                            student898_2@bigdataanalytics-worker-3:~ - Терминал
Файл Правка Вид Терминал Вкладки Справка
>>> waterwarked data = extended data.withWatermark("receive time", "30 seconds")
>>> waterwarked_data.printSchema()
root
 |-- time_id: string (nullable = true)
 |-- ping_ms: string (nullable = true)
 |-- temperature_c: string (nullable = true)
 -- humidity_p: string (nullable = true)
|-- offset: long (nullable = true)
|-- receive_time: timestamp (nullable = false)
>>> extended_data.printSchema()
root
 -- time_id: string (nullable = true)
 |-- ping_ms: string (nullable = true)
 |-- temperature_c: string (nullable = true)
|-- humidity_p: string (nullable = true)
|-- offset: long (nullable = true)
|-- receive_time: timestamp (nullable = false)
>>>
             Схема не поменялась. Вотермарка только следит за чекпойнтом, но никак не
             аффектит наши данные.
             Теперь данные можно проверить на наличие дубликатов. Дубли проверяем по двум
             колонкам: `species` и `receive_time`. Таким образом будут отсеиваться дубли по
             полю `species` внутри одного микробатча, так как столбец `receive_time` для
             всех записей внутри этого микробатча одинаковый. Для этого пишем новый датасет
             deduplicated data
             deduplicated_data = waterwarked_data.drop_duplicates(["humidity p",
             "receive time"])
                                            student898_2@bigdataanalytics-worker-3:~ - Терминал
Файл Правка Вид Терминал Вкладки Справка
>>> deduplicated_data = waterwarked_data.drop_duplicates(["humidity_p", "receive_time"])
             В другом окне удаляем папку чекпоитс
             hdfs dfs -rm -f -r checkpoints
                                            student898_2@bigdataanalytics-worker-3:~ - Терминал
Файл Правка Вид Терминал Вкладки Справка
[student898_2@bigdataanalytics-worker-3 ~]$ hdfs dfs -rm -f -r checkpoints
22/01/24 19:14:44 INFO fs.TrashPolicyDefault: Moved: 'hdfs://bigdataanalytics-head-0.mcs.local:8020/user/student898_2/checkpoints' to trash at: hdfs://
bigdataanalytics-head-0.mcs.local:8020/user/student898_2/.Trash/Current/user/student898_2/checkpoints1643051684243/
[student898_2@bigdataanalytics-worker-3 ~]$
             stream = console output(deduplicated data , 10)
             stream.stop()
```

waterwarked\_data.printSchema()

```
student898_2@bigdataanalytics-worker-3:~ - Терминал
Файл Правка Вид Терминал Вкладки Справка
>>> +-----+
|time_id|ping_ms|temperature_c|humidity_p|offset|receive_time
| hull | null | null | 0 | 2022-01-24 19:16:08.083
>>> 22/01/24 19:16:15 WARN streaming.ProcessingTimeExecutor: Current batch is falling behind. The trigger interval is 10000 milliseconds, but spent 10
422 milliseconds
Batch: 1
|time_id|ping_ms|temperature_c|humidity_p|offset|receive_time
Batch: 2
|time_id|ping_ms|temperature_c|humidity_p|offset|receive_time
|null |null |null |12 |2022-01-24 19:16:23.171|
Batch: 3
|time_id|ping_ms|temperature_c|humidity_p|offset|receive_time
stream.stop()
>>> stream.stop()
```

```
Создаём временное окно. В структуру датафрейма добавился новый столбец.

windowed_data = extended_data.withColumn("window_time",
F.window(F.col("receive_time"), "2 minutes"))

windowed_data.printSchema()

Мы добавили колонку withColumn, сделали receive_time"), "2 minutes
```

```
student898_2@bigdataanalytics-worker-3:~ - Терминал
Файл Правка Вид Терминал Вкладки Справка
>>> windowed_data = extended_data.withColumn("window_time", F.window(F.col("receive_time"), "2 minutes"))
>>> windowed_data.printSchema()
root
 |-- time_id: string (nullable = true)
|-- ping_ms: string (nullable = true)
 -- temperature_c: string (nullable = true)
 |-- humidity_p: string (nullable = true)
|-- offset: long (nullable = true)
|-- receive_time: timestamp (nullable = false)
 |-- window_time: struct (nullable = false)
|-- start: timestamp (nullable = true)
      |-- end: timestamp (nullable = true)
              Ещё на это окно надо установить вотермарку
              Устанавливаем вотермарку для очистки чекпоинта и удаляем дубли в каждом окне.
              waterwarked windowed data = windowed data.withWatermark("window time", "2
              minutes")
              deduplicated windowed data = waterwarked windowed data \
                    .drop_duplicates(["humidity_p", "window_time"])
                                                student898_2@bigdataanalytics-worker-3:~ - Терминал
Файл Правка Вид Терминал Вкладки Справка
>>> waterwarked_windowed_data = windowed_data.withWatermark("window_time", "2 minutes")
>>> deduplicated windowed data = waterwarked windowed data \
       .drop_duplicates(["humidity_p", "window_time"])
>>>
              Сначало надо удвлить чекпинты
```

Проверяем как удаляются дубли из каждого окна.

```
stream = console_output(deduplicated_windowed_data , 20)
stream.stop()
```

```
функции `F.window` первый аргумент это колонка (временная метка), по которой создаётся окно; второй аргумент - ширина окна; третий - сдвиг окна. Добавляем вотермарку и указываем колонки, по которым будем исключать дубли.

sliding_data = extended_data.withColumn("sliding_time",
F.window(F.col("receive_time"), "1 minute", "30 seconds"))

waterwarked_sliding_data = sliding_data.withWatermark("sliding_time", "2 minutes")

deduplicated_sliding_data = waterwarked_sliding_data.drop_duplicates(["humidity_p", "sliding_time"])

deduplicated_sliding_data.printSchema()
```

Аналогично предыдущему пункту создаём дополнительное поле `sliding time`. В

```
х student898_2@bigdataanalytics-worker-3:~-Терминал — + × Файл Правка Вид Терминал Вкладки Справка

>>> sliding_data = extended_data.withColumn("sliding_time", F.window(F.col("receive_time"), "1 minute", "30 seconds"))

>>> waterwarked_sliding_data = sliding_data.withWatermark("sliding_time", "2 minutes")

>>> deduplicated_sliding_data = waterwarked_sliding_data.drop_duplicates(["humidity_p", "sliding_time"])

>>> deduplicated_sliding_data.printSchema()

root

|-- time_id: string (nullable = true)
|-- temperature_c: string (nullable = true)
|-- temperature_c: string (nullable = true)
|-- offset: long (nullable = true)
|-- receive_time: timestamp (nullable = false)
|-- sliding_time: struct (nullable = true)
| |-- start: timestamp (nullable = true)
| |-- end: timestamp (nullable = true)
| |-- end: timestamp (nullable = true)
```

```
очищаем папку чекпоинтов. Запускаем стрим.

stream = console_output(deduplicated_sliding_data, 5)

stream.stop()
```

```
Переопределяем метод `console_output` так, чтобы можно было задавать режим вывода результата работы arrperaционных функций.

def console_output(df, freq, out_mode):
    return df.writeStream.format("console") \
        .trigger(processingTime='%s seconds' % freq ) \
        .options(truncate=False) \
        .option("checkpointLocation", "checkpoints/watermark_console_chk2") \
        .outputMode(out_mode) \
        .start()

waterwarked_windowed_data.printSchema()
```

```
Сделаем новый датафрейм/стрим

count_data = waterwarked_windowed_data.groupBy("window_time").count()

очистим папку чекпоинтов

stream = console_output(count_data, 10, "update")

stream.stop()
```

```
student898_2@bigdataanalytics-worker-3:~ - Терминал
Файл Правка Вид Терминал Вкладки Справка
|window_time
                                       |count|
[2022-01-24 19:34:00, 2022-01-24 19:36:00]|6
22/01/24 19:35:10 WARN streaming.ProcessingTimeExecutor: Current batch is falling behind. The trigger interval is 10000 milliseconds, but spent 10897 milliseconds
Batch: 1
|window time
                                       | count|
|[2022-01-24 19:34:00, 2022-01-24 19:36:00]|12 |
+-----+
Batch: 2
|window time
|[2022-01-24 19:34:00, 2022-01-24 19:36:00]|18 |
Batch: 3
|window_time
|[2022-01-24 19:34:00, 2022-01-24 19:36:00]|24
stream.stop()
>>> stream.stop()
>>>
```

```
complete
```

```
очистим папку чекпоинтов
```

```
stream = console_output(count_data, 10, "complete")
stream.stop()
```

```
student898_2@bigdataanalytics-worker-3:~ - Терминал
Файл Правка Вид Терминал Вкладки Справка
Batch: 0
|window_time
                                    count
[2022-01-24 19:36:00, 2022-01-24 19:38:00]|6
Batch: 1
|window time
                                    Icountl
|[2022-01-24 19:36:00, 2022-01-24 19:38:00]|12 |
+-----+
Batch: 2
|[2022-01-24 19:36:00, 2022-01-24 19:38:00]|18 |
Batch: 3
|window_time
|[2022-01-24 19:36:00, 2022-01-24 19:38:00]|24
stream.stop()
>>> stream.stop()
>>>
```

# append

#### очистим папку чекпоинтов

Пишем все записи только один раз. Информация выводится один раз, когда окно заканчивается.

```
stream = console_output(count_data, 10, "append")
```

stream.stop()

выходят пустые значения, агрегирующие функции не поддерживаются

```
student898_2@bigdataanalytics-worker-3:~ - Терминал
Файл Правка Вид Терминал Вкладки Справка
Batch: 0
|window_time|count|
22/01/24 19:39:35 WARN streaming.ProcessingTimeExecutor: Current batch is falling behind. The trigger interval is 10000 milliseconds, but spent 16158 milliseconds
Batch: 1
|window time|count|
+----+
Batch: 2
| window time|count|
[Stage 64:=====>> (26 + 1) / 200]stream.stop()
22/01/24 19:39:51 ERROR v2.WriteToDataSourceV2Exec: Data source writer org.apache.spark.sql.execution.streaming.sources.MicroBatchWriter@66d7d6f6 is a ∩
borting.
22/01/24 19:39:51 ERROR v2.WriteToDataSourceV2Exec: Data source writer org.apache.spark.sql.execution.streaming.sources.MicroBatchWriter@66d7d6f6 abor
ted.
22/01/24 19:39:51 WARN hdfs.DFSClient: Caught exception
            Сджойнить стрим со статикой.
            Создадим статический датафрейм, который будет расширять исходный датасет
            (объединение потоков)
            static_df_schema = StructType() \
                  .add("humidity p", StringType()) \
                  .add("temperature c", StringType())
                                                  igor@igor-MS-7808: ~ - Терминал
Файл Правка Вид Терминал Вкладки Справка
stream.stop()
>>> client_loop: send disconnect: Broken pipe
            Написать скрипт на python для конвертации файла csv в
            json
            # importing the required libraries
            import csv
```

import json

```
# defining the function to convert CSV file to JSON file
def convjson(csvFilename, jsonFilename):
  # creating a dictionary
  mydata = \{\}
  # reading the data from CSV file
  with open(csvFilename, encoding = 'utf-8') as csvfile:
     csvRead = csv.DictReader(csvfile)
     # Converting rows into dictionary and adding it to data
     for rows in csvRead:
       mykey = rows['S. No.']
       mydata[mykey] = rows
  # dumping the data
  with open(jsonFilename, 'w', encoding = 'utf-8') as jsonfile:
    jsonfile.write(json.dumps(mydata, indent = 4))
# filenames
csvFilename = r'mydatalist.csv'
jsonFilename = r'mydatalist.json'
# Calling the convison function
```

convjson(csvFilename, jsonFilename)

Источник: https://pythonpip.ru/examples/preobrazovanie-fayla-csv-v-json-v-python